



Kolektif Öğrenme 2. Ödev Raporu

Öğrenci Adı: Emir Kaan SALT

Öğrenci Numarası: 24501073

1. Çalışmanın Amacı

Bu çalışmanın temel amacı, tez başlığı ve özeti gibi kısa metinleri kullanarak tezlerin yazım yılını tahmin etmektir. Bu doğrultuda:

- Üç farklı metin temsili (yalnızca başlık, yalnızca özet, başlık + özet),
- Üç farklı ansambl regresyon yöntemi (Bagging, Random Subspace, Random Forest),
- Bu yöntemlere ait farklı hiperparametre ayarları birbirleriyle karşılaştırılmıştır.

Bu kapsamda şu sorulara yanıt aranmıştır:

- Hangi metin türü yıl tahmini için daha fazla bilgi taşımaktadır?
- Aynı temsil üzerinde hangi ansambl algoritması daha iyi performans göstermektedir?
- Hangi hiperparametreler hata miktarını azaltmaktadır?
- Modellerin hata dağılımı ve açıklama güçleri temsil türüne göre nasıl değişmektedir?

Bu çalışma, kısa metinlerden yıl tahmini yapmanın zorluğunu ve farklı temsiller ile ansambl yöntemlerinin etkilerini sistematik biçimde analiz etmeyi amaçlamaktadır.

2. Veri Hazırlığı

Çalışmada kullanılan veri seti yıllara göre düzenlenmiş tez kayıtlarından oluşmaktadır. Her yıl için toplam 500 tez örneği alınmış ve bu örnekler eğitim ve test aşamalarında dengeli dağılım sağlamak amacıyla ikiye ayrılmıştır:

- 250 örnek eğitim,
- 250 örnek test.

Bu işlem her yıl için ayrı ayrı uygulanmış, böylece veri seti tüm yıllarda aynı örnek sayısına sahip olacak şekilde dengelenmiştir.

Bu yaklaşımın avantajları:

- Modeller tüm yıllardan eşit temsil öğrenir, yıl dengesizliği oluşmaz.
- Test verisi, eğitim verisiyle aynı yılları kapsasa da farklı örneklerden oluştuğu için adil bir değerlendirme yapılır.
- Tahmin performansı belirli yıllara kayma göstermeden genel bir eğilimi yansıtır.

Tüm işlemler sonunda her temsil metoduna ait eğitim ve test kümeleri oluşturulmuş ve embedding işlemlerine hazır hale getirilmiştir.

3. Metin Temsillerinin Oluřturulması

Çalıřmada üç farklı metin temsili kullanılmıřtır. Bu temsiller tez bařlıkları ve özetlerinin semantik ieriklerini modelin anlayabileceėi sayısal vektörlere dönüřtürmeyi amaçlar.

3.1 Yalnızca Bařlık Temsili

- Bu temsilde yalnızca tez bařlıkları embedding modeline verilmiřtir.
- Her tez, kısa bir metin parası olan bařlık üzerinden temsil edilmiřtir.
- Bařlıklar kısa ve odaklı olduėundan ierik bilgisi sınırlıdır.
- Ancak belirli tematik ipuları ierdiėinden, yıl tahmininde belirli düzeyde bilgi sağlayabilmesi beklenmektedir.

3.2. Yalnızca Özet Temsili

- Bu temsilde yalnızca tezlerin özet bölümleri kullanılmıřtır.
- Özetler daha uzun ve ierik açısından zengin olduėundan embedding modeli daha kapsamlı semantik bilgi üretmektedir.
- Bu nedenle özet temsili, bařlık temsiline kıyasla daha güçlü bir yıl tahmin performansı sergilemesi beklenmektedir.

3.3. Birleřtirilmiř Temsil (Bařlık + Özet)

- Bu temsilde bařlık ve özet, tek bir metin haline getirilerek embedding modeline birlikte verilmiřtir.
- Böylece bařlığın odaklı bilgisi ile özetin geniş ierik bilgisi aynı vektörde birleřtirilmiřtir.
- Bu yaklaşım, modelin iki farklı kaynaktaki bilgiyi bütünsel olarak kullanmasına imkân tanımaktadır.

4. Kullanılan Ansambl Modelleri

Çalışmada üç farklı karar ağacı tabanlı ansambl regresyon yöntemi uygulanmıştır. Üçünün de temel bileşeni, tek bir karar ağacının yerine çok sayıda ağacın birlikte kullanılması ve bu ağaçların çıktılarının ortalamasının alınmasıdır.

4.1 Bagging

Bu yöntemde tüm özellikler her ağaç için aynen kullanılmış ve ağaçlar arasındaki çeşitlilik örnek bazında sağlanmıştır:

- Her ağaç eğitim verisinden, geri koymalı rastgele örnekleme ile oluşturulan farklı bir alt küme üzerinde eğitilmiştir (bootstrap örnekleri).
- Bazı eğitim örnekleri aynı ağaçta birden fazla kez yer alabilir, bazıları hiç yer almayabilir.

Hiperparametre aramasında aşağıdaki ayarlar sistematik olarak değerlendirilmiştir:

- Ağaç sayısı
- Örnek oranı
- Ağacın derinliği

Dolayısıyla Bagging modeli örnek çeşitliliğine dayalı, özelliklerin tamamını kullanan bir ansambl yaklaşımı olarak uygulanmıştır.

4.2 Random Subspace

Bu yöntemde tüm eğitim örnekleri kullanılır ancak her ağaç yalnızca özelliklerin belirli bir oranı ile eğitilir. Embedding boyutunun yüksek olması nedeniyle bu yaklaşım:

- Ağaçların farklı öznelik alt uzaylarında uzmanlaşmasını sağlar,
- Modeller arasında çeşitliliği artırarak performansı yükseltir.

Hiperparametre aramasında aşağıdaki ayarlar sistematik olarak değerlendirilmiştir:

- Ağaç sayısı
- Özellik oranı
- Ağaç derinliği

Dolayısıyla Random Subspace modeli özellik çeşitliliğine dayalı, örneklerin tamamını kullanan bir ansambl yaklaşımı olarak uygulanmıştır.

4.3 Random Forest

Bu çalışmada en agresif rastgeleleştirme yapan ansambl yöntemidir ve şu şekilde uygulanmıştır:

- Her ağaç, tıpkı Bagging'de olduğu gibi bootstrap ile seçilmiş bir örnek alt kümesi üzerinde eğitilmiştir.
- Ancak Bagging'den farklı olarak, ağaç içindeki her bir düğümde:
 - Tüm özelliklere değil, o düğüm için rastgele seçilmiş bir özellik alt kümesine bakılmıştır.
 - Bölünme kararı bu altkümedeki en iyi bölünmeye göre verilmiştir.
- Hiperparametre aramasında aşağıdaki ayarlar sistematik olarak değerlendirilmiştir:
 - Ağaç sayısı
 - Örnek oranı
 - Özellik oranı
 - Ağaç derinliği

Bu yapı sayesinde Random Forest, hem örnek bazında bootstrap yöntemiyle sağlanan çeşitliliği hem de her düğümde rastgele seçilen özellik altkümeleriyle elde edilen çeşitliliği bir arada kullanarak daha dengeli ve kararlı bir genelleme performansı hedeflemektedir.

5. Hiperparametre Optimizasyonu

5.1 Neden Hiperparametre Araması Yapılır

Bu modellerin performansı, sadece kullanılan veri ve temsil biçimine değil, aynı zamanda aşağıdaki ayarların seçimine de bağlıdır:

- Ağaç sayısı
- Her ağacın göreceği örnek oranı
- Her ağacın göreceği özellik oranı
- Ağaçların maksimum derinliği

Bu nedenle her model rastgele bir ayarla değil, sistematik bir arama sonucunda belirlenmiş en iyi ayarlarla değerlendirilmiştir.

5.2 En Başarılı Hiperparametreyi Bulma Yöntemi

Her model-temsil ikilisi için:

1. Önce denenmek istenen ayar kombinasyonları belirlenmiştir
2. Eğitim kümesi, birkaç eşit parçaya bölünmüştür.
3. Her ayar kombinasyonu için şu işlem uygulanmıştır:
 - Parçalardan biri “doğrulama”, kalanlar “eğitim” olarak kullanılır.
 - Model eğitim parçalarında eğitilir, doğrulama parçası üzerinde hata hesaplanır.
 - Bu işlem parçalar yer değiştirilerek tekrarlanır ve ortalama hata alınır.
4. Tüm kombinasyonlar için elde edilen ortalama hata değerleri karşılaştırılmış, en düşük hataya sahip ayar kombinasyonu en iyi hiperparametreler olarak seçilmiştir.

Bu süreç, her temsil (başlık, özet, birleştirilmiş) ve her model türü (Bagging, Random Subspace, Random Forest) için ayrı ayrı uygulanmıştır. Daha sonra en iyi modeller, eğitim verisinin tamamında tekrar eğitilmiş ve sadece test kümesi üzerinde nihai performansları ölçülmüştür.

6. Performans Ölçütleri ve Seçilme Nedenleri

Model performansı üç ölçüt ile değerlendirilmiştir: MAE, RMSE ve R^2 . Bu ölçütler bir regresyon problemini farklı açılardan analiz etmeye olanak sağlar.

6.1 Ortalama Mutlak Hata (MAE)

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

MAE, yıl tahmini probleminde hatanın ortalama büyüklüğünü doğrudan ve anlaşılır biçimde ölçtüğü için temel performans göstergesi olarak tercih edilmiştir. Özellikle tez yılı gibi sınırlı varyansa sahip bir hedef değişkende hatanın sade ve yorumlanabilir bir ölçümü gerekir; MAE bu ihtiyacı en net şekilde karşılar.

MAE'nin bu çalışmada tercih edilme nedenleri:

- Tahmin ile gerçek yıl arasındaki farkı doğrudan ölçer.
- Aykırı değerlere karşı dayanıklıdır.
- Hatanın büyüklüğünü sade ve anlaşılır biçimde ifade eder.
- Yıl tahmini gibi dar aralıklı hedeflerde güvenilir ve stabil bir hata ölçütü sağlar.

6.2 Kök Ortalama Kare Hatası (RMSE)

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

RMSE, hataların karelerini aldığı için büyük hatalara daha yüksek ağırlık verir ve modelin belirli yıllardaki aşırı sapmalarını görünür hâle getirir. Bu nedenle, yalnızca ortalama hatayı değil, hatanın dağılımındaki dengesizlikleri ve uç sapmaları tespit etmek için MAE'nin tamamlayıcı bir ölçütü olarak kullanılmıştır.

RMSE'nin bu çalışmada tercih edilme nedenleri:

- Büyük hataları daha güçlü cezalandırır.
- Modelin belirli yıllarda sistematik sapma yapıp yapmadığını ortaya çıkarır.
- Hatanın dağılımını daha hassas biçimde analiz etmeyi sağlar.
- MAE ile birlikte kullanıldığında çok yönlü hata değerlendirmesi sunar.

6.3 Belirleme Katsayısı (R²)

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$$

R², modelin yıl bilgisindeki toplam varyansın ne kadarını açıklayabildiğini ölçer. Tez yılı doğal olarak dar bir aralıkta değiştiği için R²'nin mutlak değeri düşük olabilir ancak temsil türleri arasında modelin ne kadar bilgi yakaladığını anlamada son derece bilgilendiricidir. Bu nedenle R² bu çalışmada mutlak performans ölçütü olarak değil, karşılaştırma aracı olarak kullanılmıştır.

R²'nin bu çalışmada tercih edilme nedenleri:

- Temsil türleri arasındaki görelî bilgi taşıma kapasitesini karşılaştırır.
- Modelin yıl bilgisini ne ölçüde açıklayabildiğini gösterir.
- MAE ve RMSE'nin açıklayamadığı “varyans açıklayıcılığı” perspektifini ekler.
- Farklı modellerin ve temsillerin görelî katkılarını analiz etmeye imkân tanır.

7. GRAFİK VE TABLO YORUMLARI

Bu bölümde, üç farklı metin temsili (Başlık, Özet, Birleşik) ve üç farklı ansambl modelinin (Bagging, Random Subspace, Random Forest) performans karşılaştırmaları, hiperparametre davranışları ve tahmin dağılımları bütüncül bir şekilde yorumlanmaktadır.

7.1 Temsil Bazında Performans Karşılaştırması

	Representation	Model	MAE	RMSE	R2
3	Abstract	Bagging	5.147714	6.100065	0.223427
5	Abstract	Random Forest	5.153005	6.090055	0.225973
4	Abstract	Random Subspace	5.167916	6.110485	0.220772
6	Combined	Bagging	5.224233	6.214464	0.194026
8	Combined	Random Forest	5.227108	6.193490	0.199458
7	Combined	Random Subspace	5.272355	6.247952	0.185317
2	Title	Random Forest	5.683112	6.624457	0.084172
0	Title	Bagging	5.683320	6.631952	0.082098
1	Title	Random Subspace	5.700363	6.646451	0.078081

7.1.1 En iyi temsil neden Abstract oldu?

Özet metinleri:

- Başlığa göre çok daha uzun ve kapsamlıdır.
- Tezin amacı, yöntemleri ve bulguları gibi yıl bilgisiyle ilişkili çok daha fazla ipucu içerir.
- Bu nedenle embedding'e dönüştürüldüğünde daha zengin ve ayırt edici vektörler üretir.

Bu durum doğrudan performans metriklerine yansımıştır:

- En düşük MAE değerleri abstract temsiline aittir.
- En yüksek R^2 değerleri yine abstract temsilindedir.
- Tüm modeller abstract üzerinde en iyi performansı göstermiştir.

7.1.2 Title neden en zayıf temsil oldu?

Başlık metinleri:

- Çok kısadır.
- Yıl bilgisini taşıyacak ayrıntı ve içerikten yoksundur.
- Embedding modeli için çok sınırlı sinyal sağlar.

- Kısa metinlerde kelime çeşitliliği düşük olduğundan, yıl ile ilişkili kalıplar embedding içine yansımaz.

Bu durum sonuçlara açıkça yansımıştır:

- En yüksek MAE değerleri Title temsiline aittir.
- En düşük R^2 yine Title temsilinde görülmektedir.

7.1.3 Combined neden Abstract'tan daha kötü oldu?

Birleşik temsilin normal şartlarda daha yüksek performans vermesi beklenir. Çünkü başlık ve özetin birlikte kullanılması modelin iki farklı kaynaktan bilgi almasını sağlar. Ancak bu çalışmada Abstract temsili daha güçlü sonuçlar üretmiştir. Bunun temel nedeni:

- Yeni bir özellik yerine, zayıf bir tekrar oluşturmuştur.
- Modele küçük miktarda gürültü eklemiştir.


Bu nedenle başlık eklemek, abstract'ın güçlü sinyalini artırmak yerine hafifçe zayıflatmış olabilir.

Bu durum sonuçlara yansımıştır:

- Combined temsili abstract'tan daha kötü MAE değerleri üretmiştir.
- R^2 değerleri de abstract'ın gerisinde kalmıştır.

7.2. Bagging Modelinde Hiperparametrelerin Performansa Etkisi

Abstract temsili üzerinde yapılan hiperparametre taraması, Bagging yönteminin hata değerlerinin belirli ayarlarla nasıl değiştiğini açık biçimde göstermektedir. Grafikler incelendiğinde aşağıdaki bulgular dikkat çekmektedir.



7.2.1 Ağaç Sayısının Etkisi

Ağaç sayısı artırıldığında MAE değeri belirgin biçimde düşmüştür. Bu durum Bagging'in temel prensibiyle uyumludur:

- Birlikte kullanılan ağaç sayısı arttıkça varyans azalır.
- Modele giren rastgelelik ortalaması alınarak daha istikrarlı tahminler elde edilir.


7.2.2 Örnek Sayısının Etkisi

Alt örnekleme oranı arasında arttıkça MAE düşmüştür. Bunun nedeni:

- Eğitim için daha fazla örnek kullanıldığında her ağacın sahip olduğu bilgi artar.
- Abstract temsili zaten zengin özelliklere sahip olduğu için daha geniş veri ile daha istikrarlı sonuçlar elde edilir.

7.3 Random Subspace Modelinde Hiperparametrelerin Performansa Etkisi

Random Subspace yöntemi, özellik (feature) alt örnekleme uygulayan bir ansambl tekniğidir. Abstract temsili üzerinde yapılan hiperparametre taraması, bu yöntemin hataya nasıl tepki verdiğini açık biçimde göstermektedir.



7.3.1 Ağaç Sayısının Etkisi

Ağaç sayısı artırıldığında MAE düşmüştür. Bunun nedeni:

- Random Subspace özellikleri rastgele seçerek ağaçları daha farklı hale getirir.
- Ağaç sayısı artırıldığında, farklı ağaçların ürettiği tahminler bir araya getirilerek ortak bir sonuç oluşturulur ve bu birleşim gürültüyü azaltarak daha kararlı bir tahmin üretir.





7.3.2 Özellik Sayısının Etkisi

Gözlenen durum 0.5 değeri en düşük hatayı üretmiştir.

- Çok daha düşük değer (0.3) kullanıldığında:
 - Her ağaç veri setinin bilgi kapasitesinin büyük kısmını göremez.
 - Bu da modele “fazla rastgelelik” ekler, hata yükselir.
- Çok daha yüksek değer (0.8) kullanıldığında:
 - Ağaçlar birbirine benzemeye başlar.
 - Çeşitlilik azalır, ansambl etkisi zayıflar.

7.4. Random Forest Modelinde Hiperparametrelerin Performansa Etkisi

Random Forest, hem örnek hem de özellik alt örnekleme yapan, bagging tabanlı güçlü bir ansambl yöntemidir. Abstract temsili üzerinde yapılan hiperparametre analizi, bu modelin hata davranışını açık şekilde göstermektedir.



7.4.1 Ağaç Sayısının Etkisi

Ağaç sayısı artırıldığında MAE azalmıştır. Bu düşüşün nedeni:

- Random Forest, bootstrap örnekleme + rastgele özellik seçimi kullandığı için ağaçlar arasında doğal çeşitlilik zaten yüksektir.
- Gürültü etkisi azalır ve ortalama tahmin daha stabil olur.

7.4.2 Özellik Sayısının Etkisi

Gözlenen durum:

- $\log_2$ en kötü performansı üretmiştir.
 - Bunun nedeni, seçilen özellik sayısının aşırı azalması ve ağaçların veri yapısını yeterince temsil edememesidir.
- 0.5 ve $\sqrt{\cdot}$ oldukça benzer sonuç vermiştir, ancak:
 - 0.5 değeri biraz daha düşük hata üretmiştir.
 - $\sqrt{\cdot}$ değeri ise daha klasik ve stabil bir Random Forest ayarıdır.

7.4.3 Örnek Sayısının Etkisi

En iyi sonuç 0.8 oranında elde edilmiştir çünkü:

- Bu oran hem yeterli sayıda örneğin her ağaca ulaşmasını sağlar hem de tam örnek kullanımında kaybolan çeşitliliği korur.

0.5 Oran:


- Her ağaç daha az örnek gördüğü için veri yapısı zayıf temsil edilir ve hata artar.

1.0 Oran:

- Tüm örneklerin kullanılması ağaçları birbirine benzer hale getirir, çeşitlilik azalır ve ansambl etkisi zayıflar.

7.5 Temsil Türlerine Göre Model Performanslarının Karşılaştırılması

Her üç model için de (Bagging, Random Subspace, Random Forest) temsil türlerine göre elde edilen MAE değerleri incelendiğinde benzer bir eğilim gözlemlenmiştir. Modeller arasındaki temel farklılıklara rağmen, temsil türlerinin sağladığı bilginin model performansı üzerindeki etkisi oldukça tutarlı görünmektedir.



7.5.1 Başlık Temsil Performansı

Tüm modellerde başlık temsili en yüksek MAE değerine sahiptir. Bunun nedeni:

- Tez başlıklarının kısa ve sınırlı bilgi içermesi,
- Yıl tahmini için yeterli ipucu üretmemesi,
- İçerik çeşitliliğini yansıtmada yetersiz kalmasıdır.

7.5.2 Özet Temsil Performansı

Her üç modelde de en düşük MAE değerine sahiptir. Bu durum şu sebeplerle tutarlıdır:

- Özetler, tezin kapsamını, konusunu ve metodolojisini daha iyi yansıtan zengin bir semantik içeriğe sahiptir.
- Embedding modeli daha güçlü bir temsile ulaşır.
- İçerik derinliği arttıkça modellerin yıl tahmini yapacak sinyalleri yakalama kapasitesi yükselir.

7.5.3 Birleştirilmiş Temsil Performansı

Her modelde abstract'tan bir miktar daha yüksek MAE üretmiştir. Yani birleşik temsil abstract kadar güçlü değildir.

Bunun olası nedenleri:

- Başlık, abstract içinde zaten bulunan bilginin kısa bir tekrarından ibarettir.
- Yeni bir sinyal eklemek yerine gürültü oluşturmuş olabilir.
- Model, zaten abstract'tan aldığı bilgiyi başlıkla güçlendirmek yerine zayıflatmış olabilir.


Bu durum, metin temsillerinde bilgi eklemenin her zaman performansı artırmadığını göstermektedir.

7.5.4 Modeller Arasında Genel Eğilim

Sonuç olarak Bagging, Random Subspace ve Random Forest farklı ansambl stratejilerine sahip olsalar da aynı sıralamayı takip etmektedir. Bu da temsil türünün model türünden daha baskın bir faktör olduğunu göstermektedir.

7.6 Modellere Göre Temsil Bazında Performans Karşılaştırılması

Üç grafik birlikte değerlendirildiğinde, temsil türü değişse bile modeller arasındaki performans farklarının oldukça sınırlı olduğu görülmektedir. Bagging, Random Subspace ve Random Forest birbirine benzer MAE değerleri üretmiş olup aradaki farklar yalnızca küçük ölçekte kalmıştır. Bu durum, model seçiminin etkisinin sınırlı olduğunu, asıl belirleyici faktörün temsil türü olduğunu da yeniden doğrulamaktadır.



7.6.1 Bagging Performansı

Bagging, tüm özellikleri eksiksiz kullanması ve yalnızca örnek bazında rastgelelik uygulaması sayesinde en düşük hata değerini elde etmiştir. Bunun temel nedenleri şunlardır:

- Tüm özelliklerin kullanılması, embedding temsillerindeki semantik bilginin eksiksiz öğrenilmesini sağlamıştır.
- Bootstrap örnekleme ağaçlar arasındaki varyansı düşürerek daha kararlı ve istikrarlı tahminler üretmiştir.

7.6.2 Random Subspace Performansı

Random Subspace modelinde rastgele özellik seçimi, embedding temsillerinin yüksek boyutlu yapısı nedeniyle performansı olumsuz etkilemiştir. Modelin daha zayıf sonuç vermesinin temel nedenleri şunlardır:

- Özelliklerin belirli oranda azaltılması, her ağacın veriyi daha sınırlı görmesine yol açmış ve öğrenme kapasitesi düşmüştür.
- Bilgi kaybı arttıkça model, karmaşık tematik yapıları yakalamakta zorlanmış ve hata seviyesi diğer yöntemlere kıyasla daha yüksek kalmıştır.

7.6.3 Random Forest


Hem örnek hem özellik bazlı rastgelelik uyguladığı için iki uç model arasında dengeli bir performans sergilemiştir. Performans özellikleri şöyle özetlenebilir:

- Her düğümde sınırlı sayıda özellik kullanılması belirli bir bilgi kaybına yol açmıştır.
- Bootstrap örnekleme bu bilgi kaybını kısmen telafi etmiş ve modelin aşırı çeşitliliğe rağmen tutarlı bir performans göstermesini sağlamıştır.

Bu nedenle Random Forest, Bagging'in altında ancak Random Subspace'in üzerinde bir hata seviyesinde konumlanmıştır.

7.7 R² Isı Haritasının Yorumlanması

R² değerleri, temsil türleri ile modeller arasındaki ilişkiyi açık biçimde göstermektedir. Genel eğilim, temsil türünün model türünden çok daha belirleyici olduğunu ortaya koymaktadır. Aşağıda her temsil için sonuçlar maddeli olarak açıklanmıştır.



7.7.1 Title Temsili

- Tüm modellerde R² değeri yaklaşık 0.08 seviyesinde kalmıştır.
- Başlıkların kısa ve sınırlı bilgi içermesi, yıl değişkenindeki varyansın yalnızca küçük bir kısmının açıklanmasına yol açmıştır.
- Model türü değişse bile sonuç değişmemekte, bu da başlık bilgisinin zayıf sinyale sahip olduğunu göstermektedir.

7.7.2 Abstract Temsili

- Tüm modellerde en yüksek R² değerlerini üretmiştir.
- Özetler içerik bakımından zengin olduğu için model yıl tahmininde kullanılan semantik ipuçlarını daha iyi yakalamıştır.
- Bagging, Random Subspace ve Random Forest arasında büyük fark olmaması, güçlü bilginin temsil tarafından sağlandığını da göstermektedir.

7.7.3 Combined Temsili


- R^2 deęerleri abstract'a gre daha dřktr.
- Bunun nedeni, bařlık bilgisinin zet iinde zaten bulunan bilginin bir tekrarını retmesi ve modele ek bir sinyal kazandırmamasıdır.
- Tekrarlı bilgi, modele katkı yerine hafif bir “grlt etkisi” yaratmıř ve R^2 sınırlı kalmıřtır.

7.7.4 Genel Deęerlendirme

- Temsil trleri arasında sıralama Abstract > Combined > Title řeklinde tutarlı biimde korunmuřtur.
- Modeller arasında ok byk fark olmamasının sebebi, yıl bilgisinin doęal varyansının dřk olması ve performansı belirleyen ana unsurun temsil kalitesi olmasıdır.
- Her  model de en yksek aıklayıcılıęı abstract temsili zerinde gstermiřtir.

7.8 Yıl Tahmin Doğruluk Dağılımlarının Yorumlanması

Modellerin gerçek yıl ile tahmin edilen yıl ilişkisini gösteren dağılım grafikleri incelendiğinde, tüm modellere ve temsil türlerine yayılmış belirgin yapısal bir eğilim gözlenmektedir. Tahminler genel olarak doğru eğilim ile uyumludur; ancak noktaların kırmızı referans doğrusuna tam oturmaması, yıl bilgilerinin sınırlı semantik sinyal içermesi nedeniyle kaçınılmaz bir hata payına işaret etmektedir.



7.8.1 Title Temsili

- Tahminler geniş bir bant şeklinde dağılmakta ve referans doğrusuna yakınlık düşüktür.
- Başlıkların kısa ve yüzeysel bilgi içermesi nedeniyle modeller yıl sinyalini zayıf yakalamış, tahminler birbirine oldukça benzer bir hata paterni oluşturmuştur.
- Modeller arasında belirgin bir fark gözlemlenmez; çünkü temsilin taşıdığı bilgi sınırlı olduğundan model çeşitliliği performansa anlamlı bir katkı yapmamıştır.

7.8.2 Abstract Temsili

- Nokta dağılımı referans doğrusuna Title temsilinden çok daha yakındır.
- Özellikle Bagging ve Random Forest tahminleri daha sıkı kümelenmiş ve aşırı sapmalar azalmıştır.
- Özetlerin içerik açısından zengin olması modellerin yıl bilgisini daha tutarlı bir şekilde yakalamasını sağlamıştır.
- En düşük sapma Abstract–Bagging ve Abstract–Random Forest grafiklerinde gözlemlenir.

7.8.3 Combined Temsili

- Combined temsili Abstract kadar güçlü değildir ancak Title’a göre daha iyidir.
- Dağılım Abstract kadar sıkı olmayıp, bazı yıllarda tahminler belirgin şekilde yukarı veya aşağı sapabilmektedir.
- Başlık bilgisi özet bilgisine ek değer üretmediğinden, Combined temsili Abstract’a göre daha geniş bir hata bandı göstermektedir.

7.8.4 Model Bazlı Sonuç

- Bagging, en tutarlı görünümü sergilemiş ve tahminler çoğunlukla orta bantta kalmıştır.
- Random Forest, Bagging’e benzer ancak biraz daha geniş hata dağılımı göstermiştir.
- Random Subspace, en geniş hata bandına sahip modeldir; özellikle Abstract ve Combined temsillerinde bazı aşırı uç noktalar belirginleşmiştir.